## Life is short, you need Spark!



# 从零开始

不需要任何基础,带领您无痛入门 Spark

# 云计算分布式大数据 Spark 实战高手之路

王家林著

Spark 亚太研究院系列丛书 版权所有

伴随着大数据相关技术和产业的逐步成熟,继 Hadoop 之后,Spark 技术以其无可比拟的优势,发展迅速,将成为替代 Hadoop 的下一代云计算、大数据核心技术。

#### 本书特点

- ▶ 云计算分布式大数据 Spark 实 战高手之路三部曲之第一部
- 网络发布版为图文并茂方式,边学习,边演练
- 不需要任何前置知识,从零开始,循序渐进

#### 本书作者



Spark 亚太研究院院长和首席专家,中国目前唯一的移动互联网和云计算大数据集大成者。在 Spark、Hadoop、Android等方面有丰富的源码、实务和性能优化经验。彻底研究了 Spark 从 0.5.0 到 0.9.1 共 13 个版本的 Spark 源码,并已完成2014 年 5 月 31 日发布的 Spark1.0 源码研究。

Hadoop 源码级专家,曾负责某知名公司的类 Hadoop 框架开发工作,专注于Hadoop 一站式解决方案的提供,同时也是云计算分布式大数据处理的最早实践者之一。

Android 架构师、高级工程师、咨询 顾问、培训专家。

通晓 Spark、Hadoop、Android、 HTML5,迷恋英语播音和健美。

- "真相会使你获得自由。"
  - 耶稣《圣经》约翰 8:32KJV
- "所有人类的不幸都来源于不能直面事实。"
  - 释迦摩尼
- "道法自然"
- 一 老子《道德经》第25章

## 《云计算分布式大数据 Spark 实战高手之路》 *系列丛书三部曲*

#### 《云计算分布式大数据 Spark 实战高手之路---从零开始》:

不需要任何基础,带领您无痛入门 Spark 并能够轻松处理 Spark 工程师的日常编程工作,内容包括 Spark 集群的构建、Spark 架构设计、RDD、Shark/SparkSQL、机器学习、图计算、实时流处理、Spark on Yarn、JobServer、Spark测试、Spark 优化等。

#### 《云计算分布式大数据 Spark 实战高手之路---高手崛起》:

大话 Spark 源码,全世界最有情趣的源码解析,过程中伴随诸多实验,解析 Spark 1.0 的任何一句源码!更重要的是,思考源码背后的问题场景和解决问题的设计哲学和实现招式。

#### 《云计算分布式大数据 Spark 实战高手之路---高手之巅》:

通过当今主流的 Spark 商业使用方法和最成功的 Hadoop 大型案例让您直达高手之巅,从此一览众山小。



2/31

www.sparkinchina.com

TEL: 4006-998-758

## 《前言》

Spark 采用一个统一的技术堆栈解决了云计算大数据的如流处理、图技术、机器学习、NoSQL 查询等方面的所有核心问题,具有完善的生态系统,这直接奠定了其一统云计算大数据领域的霸主地位;

#### 要想成为 Spark 高手,需要经历六大阶段



第一章:构建Spark集群

# ● Spark/Hadoop面试宝典 Spark/Hadoop面试宝典 Spark/Hadoop面试宝典

#### Spark 实战高手之核心技能点

#### 第一阶段:熟练的掌握 Scala 语言

- 1. Spark 框架是采用 Scala 语言编写的,精致而优雅。要想成为 Spark 高手,你就必须阅读 Spark 的源代码,就必须掌握 Scala, ;
- 2. 虽然说现在的 Spark 可以采用多语言 Java、Python 等进行应用程序开发,但是最快速的和支持最好的开发 API 依然并将永远是 Scala 方式的 API,所以你必须掌握 Scala来编写复杂的和高性能的 Spark 分布式程序;
- 3. 尤其要熟练掌握 Scala 的 trait、apply、函数式编程、泛型、逆变与协变等;

推荐课程:"精通 Spark 的开发语言:Scala 最佳实践"

#### 第二阶段:精通 Spark 平台本身提供给开发者 API

- 1. 掌握Spark中面向RDD的开发模式 掌握各种transformation和action函数的使用;
- 2. 掌握 Spark 中的宽依赖和窄依赖以及 lineage 机制;
- 3. 掌握 RDD 的计算流程,例如 Stage 的划分、Spark 应用程序提交给集群的基本过程和 Worker 节点基础的工作原理等

推荐课程:"18 小时内掌握 Spark:把云计算大数据速度提高 100 倍以上!"



TEL: 4006-998-758

#### 第三阶段:深入 Spark 内核

此阶段主要是通过 Spark 框架的源码研读来深入 Spark 内核部分:

- 1. 通过源码掌握 Spark 的任务提交过程;
- 2. 通过源码掌握 Spark 集群的任务调度;
- 3. 尤其要精通 DAGScheduler、TaskScheduler 和 Worker 节点内部的工作的每一步的细节;

推荐课程: "Spark 1.0.0 企业级开发动手:实战世界上第一个 Spark 1.0.0 课程,涵盖 Spark 1.0.0 所有的企业级开发技术"

#### 第四阶级:掌握基于 Spark 上的核心框架的使用

Spark 作为云计算大数据时代的集大成者,在实时流处理、图技术、机器学习、NoSQL 查询等方面具有显著的优势,我们使用 Spark 的时候大部分时间都是在使用其上的框架例如 Shark、Spark Streaming 等:

- 1. Spark Streaming 是非常出色的实时流处理框架 要掌握其 DStream、transformation 和 checkpoint 等;
- 2. Spark 的离线统计分析功能, Spark 1.0.0 版本在 Shark 的基础上推出了 Spark SQL, 离线统计分析的功能的效率有显著的提升,需要重点掌握;
- 3. 对于 Spark 的机器学习和 GraphX 等要掌握其原理和用法;

推荐课程: "Spark 企业级开发最佳实践"

#### 第五阶级:做商业级别的 Spark 项目

通过一个完整的具有代表性的 Spark 项目来贯穿 Spark 的方方面面,包括项目的架构设计、用到的技术的剖析、开发实现、运维等,完整掌握其中的每一个阶段和细节,这样就可以让您以后可以从容面对绝大多数 Spark 项目。

推荐课程: "Spark 架构案例鉴赏:Conviva、Yahoo!、优酷土豆、网易、腾讯、 淘宝等公司的实际 Spark 案例"

#### 第六阶级:提供Spark 解决方案

- 1. 彻底掌握 Spark 框架源码的每一个细节;
- 2. 根据不同的业务场景的需要提供 Spark 在不同场景的下的解决方案;
- 3. 根据实际需要,在 Spark 框架基础上进行二次开发,打造自己的 Spark 框架;

推荐课程:"精通 Spark: Spark 内核剖析、源码解读、性能优化和商业案例实战"



5/31

第一章:构建Spark集群

#### 《第一章:构建 Spark 集群》

对于 90%以上想学习 Spark 的人而言,如何构建 Spark 集群是其最大的难点之一,为了解决大家构建 Spark 集群的一切困难,家林把 Spark 集群的构建分为了四个步骤,从零起步,不需要任何前置知识,涵盖操作的每一个细节,构建完整的 Spark 集群。

#### 从零起步,构建 Spark 集群经典四部曲:

■ 第一步:搭建 Hadoop 单机和伪分布式环境;

■ 第二步:构造分布式 Hadoop 集群;

■ 第三步:构造分布式的 Spark 集群;

■ 第四步:测试 Spark 集群;

#### 不需任何前置知识,从零开始,循序渐进,成为 Spark 高手!





在第1讲中我们已经完成了第一步。

#### 这一讲我们构建真正的 Hadoop 分布式集群环境:

- 在VMWare 中准备第二、第三台运行 Ubuntu 系统的机器;
- 按照配置伪分布式模式的方式配置新创建运行 Ubuntu 系统的机器;
- 配置 Hadoop 分布式集群环境;
- 测试 Hadoop 分布式集群环境;

#### PS:为何搭建 Hadoop 分布式集群环境只用三台机器呢?原因如下:

- 三台机器可以让人人皆可成功配置 Hadoop 集群运行环境,不会因为现有的机器内存或者磁盘空间而不能够搭建集群环境,毕竟对于初学者来说,最重要的是先要让集群运行起来!
- 三台机器的集群环境配置的步骤和多台机器完全一致。
- 我们的教程是按照循序渐进的方式进行 "后面会有三台机器和更多机器的集群运行环境。
- 现在开始 Hadoop 分布式集群环境搭建之旅:



7/31

第一章:构建Spark集群

#### 目录

1.	在 VMWare 中准备第二、第三台运行 Ubuntu 系统的机器;	9
2.	按照配置伪分布式模式的方式配置新创建运行 Ubuntu 系统的机器;	9
3.	配置 Hadoop 分布式集群环境	.10
4.	测试 Hadoop 分布式集群环境:	.26



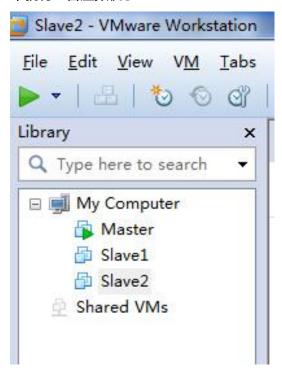
# 1. 在 VMWare 中准备第二、第三台运行 Ubuntu 系统的机器;

在 VMWare 中构建第二、三台运行 Ubuntu 的机器和构建第一台机器完全一样,再次不在赘述。。

与安装第一台 Ubuntu 机器不同的几点是:

第一点:我们把第二、三台 Ubuntu 机器命名为了 Slave1、Slave2,如下图所示:

创建完的 VMware 中就有三台虚拟机了:



第二点:为了简化 Hadoop 的配置,保持最小化的 Hadoop 集群,在构建第二、三台机器的时候使用相同的 root 超级用户的方式登录系统。

# 2. 按照配置伪分布式模式的方式配置新创建运行 Ubuntu 系统的机器:

按照配置伪分布式模式的方式配置新创建运行 Ubuntu 系统的机器和配置第一台机器 完全相同 , 下图是家林完全安装好后的截图 :



9/31

第一章:构建Spark集群





### 3. 配置 Hadoop 分布式集群环境;

根据前面的配置,我们现在已经有三台运行在 VMware 中装有 Ubuntu 系统的机器,分别是: Master、Slave1、Slave2;

下面开始配置 Hadoop 分布式集群环境:



10/31

Step 1:在/etc/hostname 中修改主机名并在/etc/hosts 中配置主机名和 IP 地址的对应关系:

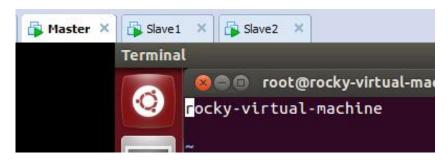
我们把 Master 这台机器作为 Hadoop 的主节点,首先看一下 Master 这台机器的 IP 地址:

可以看到当前主机的 ip 地址是 "192.168.184.133".

我们在/etc/hostname 中修改主机名:

root@rocky-virtual-machine:/# vim /etc/hostname

#### 进入配置文件:



可以看到按照我们装 Ubuntu 系统时候的默认名称,配置文件中的机器的名称是"rocky-virtual-machine",我们把"rocky-virtual-machine"改为"Master"作为 Hadoop 分布式集群环境的主节点:



11/31

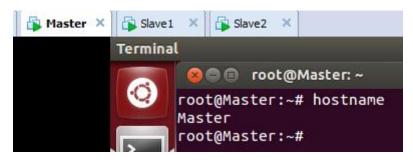
第一章:构建Spark集群



保存退出。此时使用以下命令查看当前主机的主机名:

```
root@rocky-virtual-machine:/
root@rocky-virtual-machine:/# hostname
rocky-virtual-machine
root@rocky-virtual-machine:/#
```

发现修改的主机名没有生效,为使得新修改的主机名生效,我们重新启动系统后再次查看主机名:



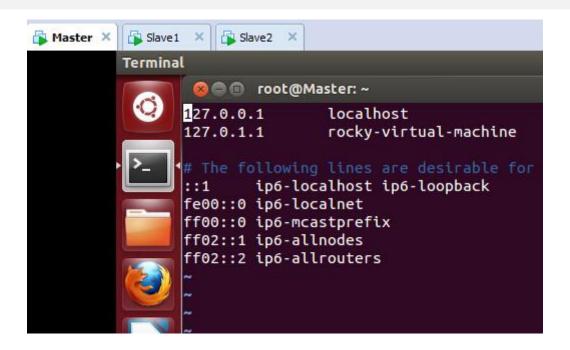
发现我们的主机名成为了修改后的"Master",表明修改成功。

打开在/etc/hosts 文件:

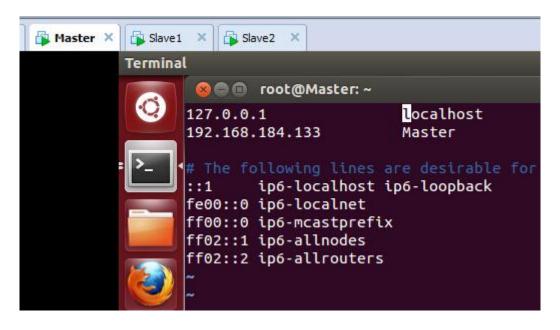


此时我们发现文件中只有 Ubuntu 系统的原始 ip( 127.0.0.1 )地址和主机名( localhost ) 的对应关系:





我们在/etc/hosts 中配置主机名和 IP 地址的对应关系:



修改之后保存退出。

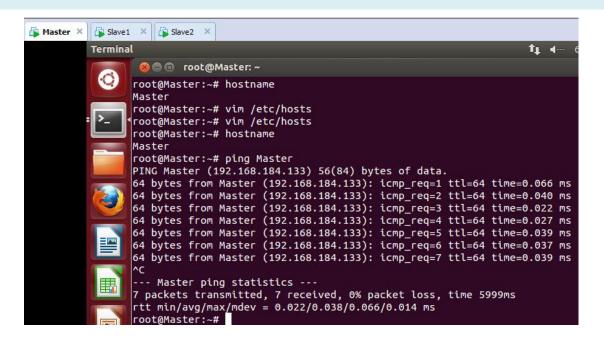
接下来我们使用 "ping" 命令看一下主机名和 IP 地址只见的转换关系是否正确:





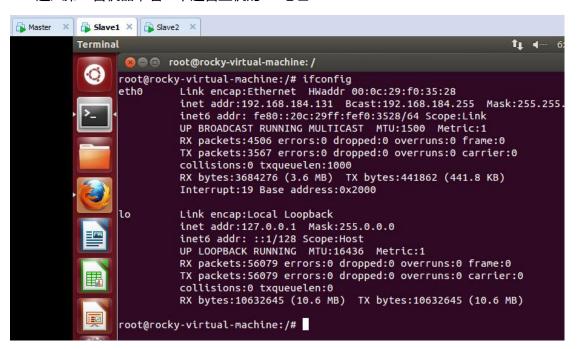
13 / 31

第一章:构建Spark集群



可以看到此时我们的主机"Master"对应的 IP 地址是"192.168.184.133", 这表明我们的配置和运行都是正确的。

进入第二台机器,看一下这台主机的 IP 地址:

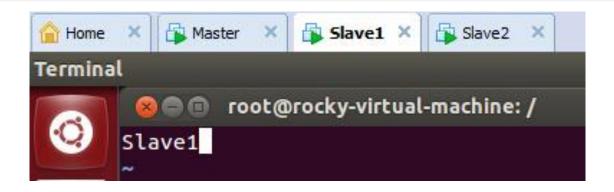


可以看出这台主机的 IP 地址是"192.168.184.131".

我们在/etc/hostname 中把主机名称修改为 "Slave1":

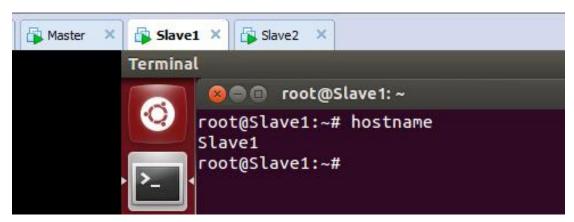


14/31



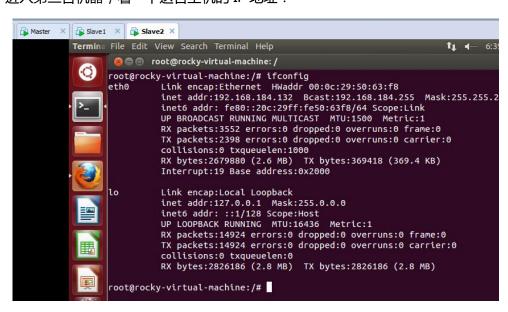
保存退出。

为了使修改生效,我们重新启动该机器,此时查看主机名:



表明我们的修改生效了。

进入第三台机器,看一下这台主机的 IP 地址:



可以看出这台主机的 IP 地址是"192.168.184.132".



亚太研究院 51CTO学院 年度推荐书籍

15/31

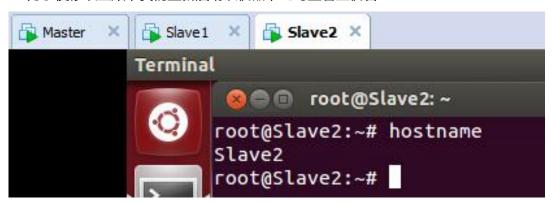
第一章:构建Spark集群

我们在/etc/hostname 中把主机名称修改为 "Slave2":



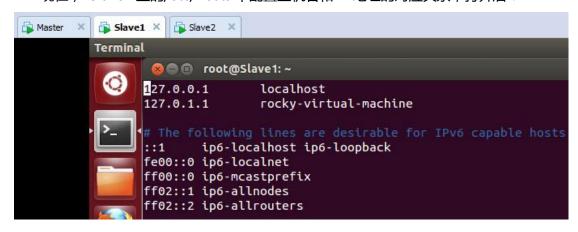
保存退出。

为了使修改生效,我们重新启动该机器,此时查看主机名:



表明我们的修改生效了。

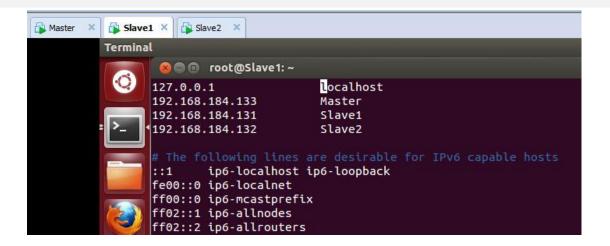
现在 , Slave1 上的/etc/hosts 中配置主机名和 IP 地址的对应关系 , 打开后:



此时我们修改为配置文件为:



16/31

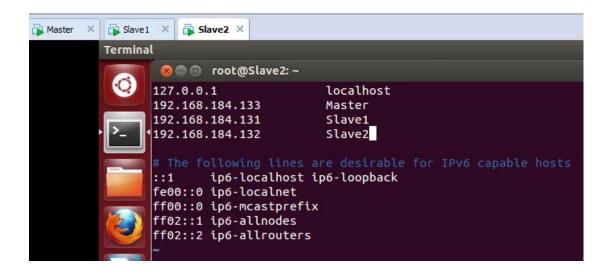


把 "Master" 和 "Slave1" 和 "Slave2" 的主机名和 IP 地址的对应关系都配置进去。 保存退出。

我们此时 ping 一下 Master 这个节点发现网络访问没有问题:

```
root@Slave1:~# ping Master
PING Master (192.168.184.133) 56(84) bytes of data.
64 bytes from Master (192.168.184.133): icmp_req=1 ttl=64 time=0.795 ms
64 bytes from Master (192.168.184.133): icmp_req=2 ttl=64 time=0.703 ms
64 bytes from Master (192.168.184.133): icmp_req=3 ttl=64 time=0.797 ms
^C
--- Master ping statistics ---
3 packets transmitted, 3 received, 0% packet loss, time 2003ms
rtt min/avg/max/mdev = 0.703/0.765/0.797/0.043 ms
root@Slave1:~#
```

接着,在 Slave2 上的/etc/hosts 中配置主机名和 IP 地址的对应关系,配置完后如下:



保存退出。



17 / 31

第一章:构建Spark集群

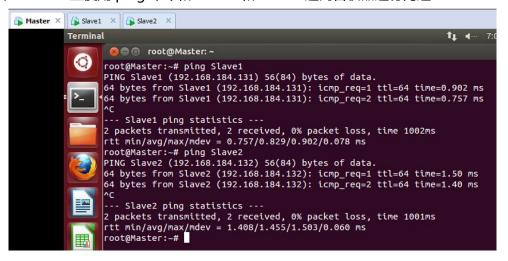
**书籍** QQ 交流群: 317540673

此时我们 ping 一下 Master 和 Slave1 发现都可以 ping 通;

最后把在 Master 上的/etc/hosts 中配置主机名和 IP 地址的对应关系,配置完后如下:

```
Master × Slave1 × Slave2 ×
          Terminal
                  🔞 🖨 🗊 root@Master: ~
                 127.0.0.1
                                         localhost
                 192.168.184.133
                                         Master
                 192.168.184.131
                                         Slave1
                192.168.184.132
                                         Slave2
                        ip6-localhost ip6-loopback
                 fe00::0 ip6-localnet
                 ff00::0 ip6-mcastprefix
                 ff02::1 ip6-allnodes
                 ff02::2 ip6-allrouters
```

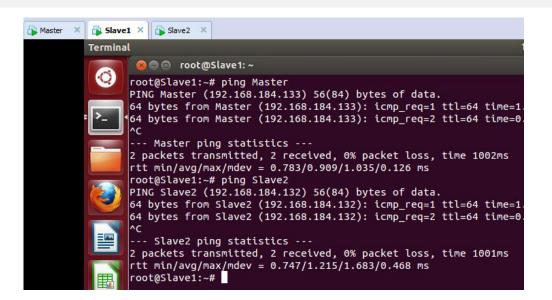
此时在 Master 上使用 ping 命令和 Slave1 和 Slave2 这两台机器进行沟通:



发现此时已经 ping 通了两个 slave 节点的机器。

最后我们在测试一下 Slave1 这台机器和 Master、Slave2 的通信:

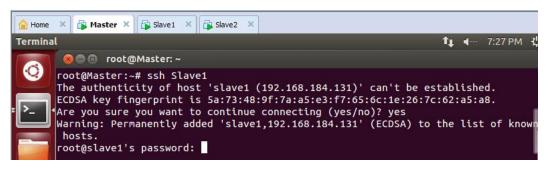




到目前为止, Master、Slave1、Slave2 这三台机器之间实现了相互通信!

Step 2: SSH 无密码验证配置

首先我们看一下在没有配置的情况下 Master 通过 SSH 协议访问 Slave1 的情况:



此时会发现我们是需要密码的。我们不登陆进去,直接退出。

怎么使得集群能够通过 SSH 免登陆密码呢?

按照前面的配置,我们已经分布在 Master、Slave1、Slave2 这三台机器上的/root/.ssh/目录下生成一个私钥 id\_rsa 和一个公钥 id\_rsa.pub。

此时把 Slave1 的 id\_rsa.pub 传给 Master,如下所示:

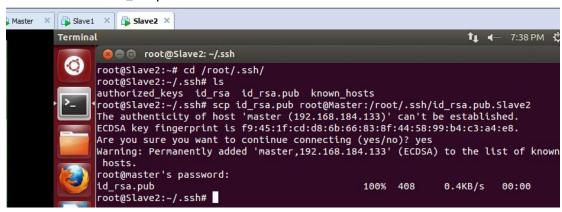


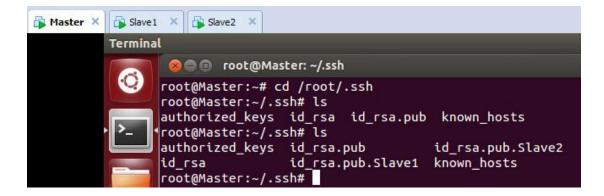
19/31

第一章:构建Spark集群



#### 同时把 Slave2 的 id\_rsa.pub 传给 Master, 如下所示:





#### 在 Master 上检查一下是否复制了过来:

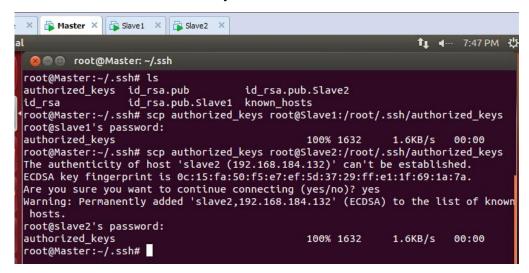
此时我们发现 Slave1 和 Slave2 节点的公钥已经传输过来 Master 节点上综合所有公钥:

```
root@Master:~/.ssh# cat id_rsa.pub >> authorized_keys
root@Master:~/.ssh# cat id_rsa.pub.Slave1 >> authorized_keys
root@Master:~/.ssh# cat id_rsa.pub.Slave2 >> authorized_keys
```

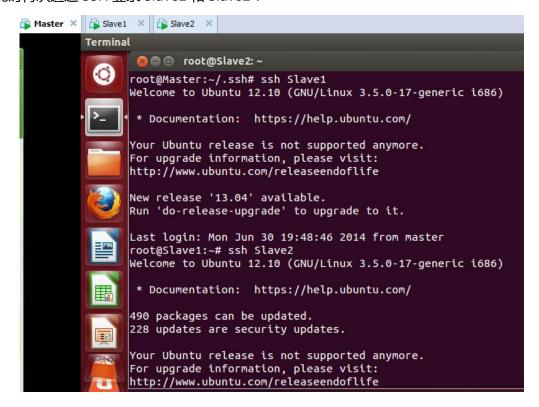


20 / 31

#### 将 Master 的公钥信息 authorized\_keys 复制到 Slave1 和 Slave1 的.ssh 目录下:



#### 此时再次通过 SSH 登录 Slave1 和 Slave2:



此时 Master 通过 SSH 登录 Slave1 和 Slave2 已经不需要密码 同样的 Slave1 或者 Slave2 通过 SSH 协议登录另外两台机器也不需要密码了。

Step 3:修改 Master、Slave1、Slave2 的配置文件

首先修改 Master 的 core-site.xml 文件, 此时的文件内容是:



21/31

第一章:构建Spark集群

```
Terminal

Termin
```

#### 我们把 "localhost" 域名修改为 "Master":

同样的操作分别打开 Slave1 和 Slave2 节点 core-site.xml, 把 "localhost" 域名修改为



22 / 31

"Master"。

其次修改 Master、Slave1、Slave2 的 mapred-site.xml 文件.

进入 Master 节点的 mapred-site.xml 文件把 "localhost" 域名修改为 "Master", 保存退出。

同理 打开 Slave1 和 Slave2 节点 mapred-site.xml 把"localhost"域名修改为"Master",保存退出。

最后修改 Master、Slave1、Slave2 的 hdfs-site.xml 文件:

```
proot@Master: /usr/local/hadoop/hadoop-1.2.1/conf
| xml version="1.0"?>
| xmme>dfs.replication<| xml version="1.0"/name>
| xml version="1.0"?>
| xmme>dfs.replication<| xml version="1.0"/name>
| xml version="1.0"?>
| xmme>dfs.replication<| xml version="1.0"/name>
| xml version="1.0"?>
| xmme>dfs.name.dir<| yml version="1.0"/name>
| xml version="1.0"?>
| xmme>dfs.name.dir<| yml version="1.0"/name>
| xml version="1.0"/name
```

我们把三台机器上的 "dfs.replication" 值由 1 改为 3,这样我们的数据就会有 3 份副本:



23 / 31

第一章:构建Spark集群

保存退出。

Step 4:修改两台机器中 hadoop 配置文件的 masters 和 slaves 文件 首先修改 Master 的 masters 文件:

```
root@Master:/usr/local/hadoop/hadoop-1.2.1/conf# vim masters
```

讲入文件:

把 "localhost" 改为 "Master":

```
    root@Master: /usr/local/hadoop/hadoop-1.2.1/conf

Master

~
```

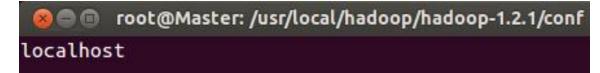


保存退出。

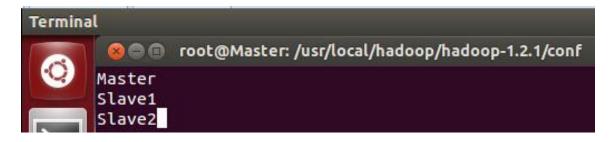
修改 Master 的 slaves 文件,

root@Master:/usr/local/hadoop/hadoop-1.2.1/conf# vim slaves

#### 进入该文件:



#### 具体修改为:



#### 保存退出。

从上面的配置可以看出我们把 Master 即作为主节点, 又作为数据处理节点, 这是考虑我们 数据的 3 份副本而而我们的机器台数有限所致。

把 Master 配置的 masters 和 slaves 文件分别拷贝到 Slave1 和 Slave2 的 Hadoop 安装目 录下的 conf 文件夹下:

```
root@Master: /usr/local/hadoop/hadoop-1.2.1/conf
oot@Master:/usr/local/hadoop/hadoop-1.2.1/conf# scp masters root@Slave1:/usr/lo
al/hadoop/hadoop-1.2.1/conf
                                             100%
                                                     7
                                                           0.0KB/s 00:00
nasters
root@Master:/usr/local/hadoop/hadoop-1.2.1/conf# scp slaves root@Slave1:/usr/loc
al/hadoop/hadoop-1.2.1/conf
                                              100%
                                                    21
                                                           0.0KB/s
                                                                     00:00
root@Master:/usr/local/hadoop/hadoop-1.2.1/conf# scp masters root@Slave2:/usr/lo
cal/hadoop/hadoop-1.2.1/conf
                                                     7
                                                           0.0KB/s 00:00
masters
oot@Master:/usr/local/hadoop/hadoop-1.2.1/conf# scp slaves root@Slave2:/usr/loc
al/hadoop/hadoop-1.2.1/conf
                                                     21
                                                           0.0KB/s
                                                                     00:00
oot@Master:/usr/local/hadoop/hadoop-1.2.1/conf#
```

进入 Slave1 或者 Slave2 节点检查 masters 和 slaves 文件的内容:





25 / 31

第一章:构建Spark集群



```
© ■ root@Slave1: /usr/local/hadoop/hadoop-1.2.1/conf
Master
Slave1
Slave2
```

发现拷贝完全正确。

至此 Hadoop 的集群环境终于配置完成!

#### 4. 测试 Hadoop 分布式集群环境;

首先在通过 Master 节点格式化集群的文件系统:

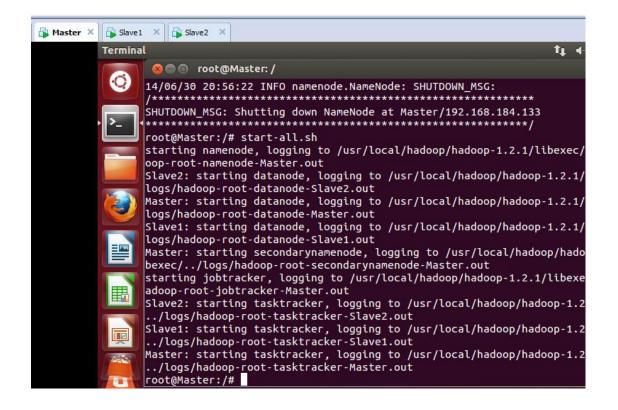
输入"Y"完成格式化:



26/31

```
🔞 🖨 📵 root@Master: ~
14/06/30 20:51:20 INFO util.GSet: recommended=4194304, actual=4194304
14/06/30 20:51:21 INFO namenode.FSNamesystem: fsOwner=root
14/06/30 20:51:22 INFO namenode.FSNamesystem: supergroup=supergroup
14/06/30 20:51:22 INFO namenode.FSNamesystem: isPermissionEnabled=true
14/06/30 20:51:22 INFO namenode.FSNamesystem: dfs.block.invalidate.limit=100
14/06/30 20:51:22 INFO namenode.FSNamesystem: isAccessTokenEnabled=false accessK
eyUpdateInterval=0 min(s), accessTokenLifetime=0 min(s)
14/06/30 20:51:22 INFO namenode.FSEditLog: dfs.namenode.edits.toleration.length
14/06/30 20:51:22 INFO namenode.NameNode: Caching file names occuring more than
10 times
14/06/30 20:51:23 INFO common.Storage: Image file /usr/local/hadoop/hadoop-1.2.1
/hdfs/name/current/fsimage of size 110 bytes saved in 0 seconds.
14/06/30 20:51:23 INFO namenode.FSEditLog: closing edit log: position=4, editlog
=/usr/local/hadoop/hadoop-1.2.1/hdfs/name/current/edits
14/06/30 20:51:23 INFO namenode.FSEditLog: close success: truncate to 4, editlog
=/usr/local/hadoop/hadoop-1.2.1/hdfs/name/current/edits
14/06/30 20:51:23 INFO common.Storage: Storage directory /usr/local/hadoop/hadoo
p-1.2.1/hdfs/name has been successfully formatted.
14/06/30 20:51:23 INFO namenode.NameNode: SHUTDOWN MSG:
/***********************
SHUTDOWN_MSG: Shutting down NameNode at Master/192.168.184.133
***************
root@Master:~#
```

#### 格式化完成以后,我们启动 hadoop 集群:



#### 我们在尝试一下停止 Hadoop 集群:

```
root@Master:/# stop-all.sh
stopping jobtracker
Slave2: stopping tasktracker
Master: stopping tasktracker
Slave1: stopping tasktracker
stopping namenode
Master: no datanode to stop
Slave1: no datanode to stop
Slave2: no datanode to stop
Master: stopping secondarynamenode
root@Master:/#
```

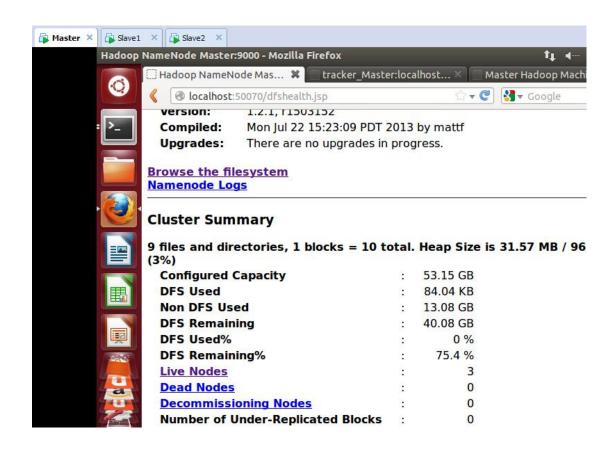
此时出现了"no datanode to stop"的错误, 出现这种错误的原因如下:

每次使用 "hadoop namenode -format" 命令格式化文件系统的时候会出现一个新的 namenodeId,而我我们在搭建 Hadoop 单机伪分布式版本的时候往我们自己创建的 tmp 目录下放了数据,现在需要把各台机器上的"/usr/local/hadoop/hadoop-1.2.1/"下面的 tmp 及其子目录的内容清空,于此同时把"/tmp"目录下的与 hadoop 相关的内容都清空,最后要把我们自定义的 hdfs 文件夹中的 data 和 name 文件夹中的内容清空:

把 Slave1 和 Slave2 中同样的内容均删除掉。

重新格式化并重新启动集群,此时进入 Master 的 Web 控制台:





此时可以看到 Live Nodes 只有三个,这正是我们预期的,因为我们 Master、Slave1、 Slave2 都设置成为了 DataNode, 当然 Master 本身同时也是 NameNode。 此时我们通过 JPS 命令查看一下三台机器中的进程信息:

```
🔞 🗎 🗈 root@Master: /usr/local/hadoop/hadoop-1.2.1/conf
root@Master:/usr/local/hadoop/hadoop-1.2.1/conf# jps
6055 JobTracker
6257 TaskTracker
12868 Jps
12235 DataNode
5969 SecondaryNameNode
12030 NameNode
root@Master:/usr/local/hadoop/hadoop-1.2.1/conf#
```



29/31

QQ 交流群: 317540673

第一章:构建Spark集群

```
cot@Slave1:/usr/local/hadoop/hadoop-1.2.1
root@Slave1:/usr/local/hadoop/hadoop-1.2.1# jps
6524 TaskTracker
6352 DataNode
6626 Jps
root@Slave1:/usr/local/hadoop/hadoop-1.2.1#
```

```
cot@Slave2:/usr/local/hadoop/hadoop-1.2.1
root@Slave2:/usr/local/hadoop/hadoop-1.2.1# jps
6542 TaskTracker
6370 DataNode
6643 Jps
root@Slave2:/usr/local/hadoop/hadoop-1.2.1#
root@Slave2:/usr/local/hadoop/hadoop-1.2.1#
```

发现 Hadoop 集群的各种服务都正常启动。

至此, Hadoop 集群构建完毕。



#### ■ Spark 亚太研究院

Spark 亚太研究院,提供 Spark、Hadoop、Android、Html5、云计算和移动互联网一站式解决方案。以帮助企业规划、部署、开发、培训和使用为核心,并规划和实施人才培训完整路径,提供源码研究和应用技术训练。

#### ■ 近期活动及相关课程

#### 决战云计算大数据时代 Spark 亚太研究院 100 期公益大奖堂

每周四晚上 20:00—21:00

课程介绍:http://edu.51cto.com/course/course\_id-1659.html#showDesc

报名参与: http://ke.qq.com/cgi-bin/courseDetail?course\_id=6167

#### 【近期 Spark 公开课】

▶ 18 小时内掌握 Spark,把云计算大数据速度提升 100 倍以上

8月10-12日 上海 8月15—17日北京

报名咨询:4006-998-758

QQ 学习交流群号: 317540673



第一章:构建Spark集群